

Sharp, Smart, and Robust Anomaly Detection

Group 9 109003814 林士智、114064545 謝尚哲、113034506 李家欣、112064520 陳若瑛、114033636 蔡旻諾

Abstract- 原始 CLIP 模型雖具備強大的零樣本 (zero-shot) 辨識能力，但在異常檢測任務中，往往因缺乏對局部細節與高頻紋理的感知能力 (Anomaly-Unawareness) 而表現受限。本研究提出 Falcon-CLIP，以模擬獵鷹對細微視覺線索的高度敏感性，系統性地解決此一問題。在方法上，我們以 AA-CLIP 架構為基礎，進一步引入多項關鍵改進，包括：頻率感知高通適配器 (Frequency-Aware High-Pass Adapter)、層級可學習門控機制 (Layer-wise Learnable Gating) 以及多尺度特徵融合策略，以強化模型對高頻紋理與局部異常模式的表徵能力。此外，我們設計了一種針對異常區域的高頻噪聲增強策略，在不破壞零樣本假設的前提下，進一步提升模型對細微瑕疵的辨識敏感度。透過上述設計，Falcon-CLIP 能在維持像素層級穩定性的同時，顯著提升影像層級的異常判別能力。實驗結果顯示，Falcon-CLIP 在 MVTEC-AD 與 MPDD 等工業異常檢測資料集上均優於現有基準方法，其中在 MPDD 上的 Image-AUROC 提升至 97.05%。此外，模型亦在醫療影像異常檢測任務中展現良好的跨領域遷移能力，驗證了其在複雜與多變場景下的穩定性與泛化性。

Keywords—Zero-shot Anomaly Detection, CLIP, Vision-Language Models

I. INTRODUCTION

A. Background

異常檢測 (Anomaly Detection) 在工業自動化品管與醫療影像診斷中扮演著至關重要的角色。隨著視覺語言模型 (Vision-Language Models, VLMs) 的發展，利用 CLIP (Contrastive Language-Image Pre-training) [1] 進行零樣本或少樣本異常檢測成為熱門的研究方向。

CLIP 利用訓練圖像編碼器 (Image Encoder) 和文字編碼器 (Text Encoder) 以預測一批 (圖像, 文字) 訓練樣本的正確配對 (如 Fig. 1 所示)。透過在大規模數據集上進行對比學習，CLIP 學習到了豐富的語義對齊資訊，使其具備強大的零樣本識別 (Zero-shot Recognition) 能力，能夠僅憑藉文字描述即對未曾見過的類別進行分類。





Fig.1 Image-Text Cosine Similarity Matrix

B. Problem Definition

然而，儘管 CLIP 在通用物體識別上表現出色，當應用於精密工業或醫療領域的異常檢測時，其效果卻不如預期。主要原因在於 CLIP 的訓練目標是全域語義對齊，而非針對局部細節的辨識。如 Fig. 2 所示，當輸入一張帶有明顯破損的地毯圖像時，標準 CLIP 模型往往給出高置信度的「正常」預測 (例如 78% 認為正常)，顯示其存在顯著的「異常感知缺失 (Anomaly-Unawareness)」問題 [2]。此外，既有的改良模型雖然引入了額外的模組，但在處理極低對比度或高頻紋理瑕疵時，其感知能力仍有待提升。受獵鷹 (Falcon) 具備高速飛行能力與極致敏銳視覺的啟發，本研究旨在設計一個能捕捉高頻細節、具備動態特徵調節能力的模型，以解決上述限制。

		“This is a [] carpet.”		
Semantics	Similarity	Probability _{c=0.01}		
broken	0.18	0.22		
normal	0.19	0.78		


		“This is a [] zipper.”		
Semantics	Similarity	Probability _{c=0.01}		
broken	0.20	0.38		
normal	0.21	0.62		

Fig.2 Examples of CLIP Anomaly-Unawareness

II. MOTIVATION

基於上述背景，本研究的動機源於解決現有模型在異常檢測上的核心缺陷。具體而言，我們可以歸納為以下幾點：

1. **Lack of Explicit Anomaly Awareness**：原始 CLIP 模型並未針對「什麼是異常」進行顯式建模，導致其無法有效捕捉圖像中的違和感或缺陷特徵。
2. **Misclassification of Anomalous Regions**：由於缺乏對高頻紋理與局部細節的關注，異常區域經常被模型忽略，進而被誤分類為正常區域。
3. **Critical in Real-world Scenarios**：在真實世界的應用場景 (如工業產線或醫療診斷) 中，異常樣本通常極為稀少且型態多樣 (Rare and Diverse)。若模型無法在少樣本或零樣本的情況下準確區分異常，將難以落地應用。

因此，本研究的目標是構建一個具備「異常感知 (Anomaly-Aware)」能力的模型——Falcon-CLIP。我們希望透過模擬獵鷹敏銳的視覺機制，強化模型對高頻細


節的捕捉能力，從而更精確地區分正常與異常區域，提升在複雜場景下的檢測效能。

III. RELATED WORK

針對 CLIP 模型在異常檢測領域的應用，近年來已有數項重要研究：

A. WinCLIP [3]


WinCLIP 首次提出了基於 CLIP 的異常評分機制，透過滑動視窗 (Window-based) 方式聚合特徵 (如 Fig. 3 所示)。然而，WinCLIP 僅依賴原始 CLIP 特徵，缺乏針對「異常語義」的顯式建模與分析，導致對複雜異常的辨識能力有限。



▲Fig.3 Workflows of WinCLIP/WinCLIP+ (upper/entire pane)

B. AnomalyCLIP [4] :


針對 WinCLIP 的語義缺失問題，AnomalyCLIP 引入了提示學習 (Prompt Learning) 機制 (如 Fig. 4 所示)。透過學習一組與物件無關 (Object-agnostic) 的可學習文本提示 (Learnable Text Prompts)，強化了模型對異常與正常狀態的語義區分能力。



▲Fig.4 Workflows of AnomalyCLIP

C. AdaCLIP [5]


AdaCLIP 進一步引入了混合語義融合 (Hybrid Semantic Fusion, HSF) 模組，並結合了多尺度聚合策略，旨在改善圖像級別的異常檢測表現 (如 Fig. 5 所示)。其核心在於透過分數融合 (Score Fusion) 與語義整合來提升魯棒性。



▲Fig.5 Workflows of AdaCLIP

D. AA-CLIP [2]

AA-CLIP 是本研究最直接的參考基線。其最大特點在於將訓練分為兩個階段：第一階段僅在文本空間進行訓練，利用 Disentangle Loss 強制區分正常與異常語義；第二階段則訓練圖像編碼器，將視覺特徵 (Visual Patches) 對齊至第一階段已確立的文本語義空間 (如 Fig. 6 所示)。儘管 AA-CLIP 表現優異，但其在特徵融合上仍採用固定權重，且推論運算較為耗時，對於高頻細節的捕捉亦有改進空間。



▲Fig.6 The Two-Stage Training Pipeline of Anomaly-Aware CLIP

IV. METHODOLOGY

A. 問題定義與目標 (Problem Setup)

我們關注 Zero-shot Anomaly Detection (ZSAD)，在不使用目標測試資料的異常標註情況下，同時完成：

1. Pixel-level anomaly localization (像素級異常定位，評估 pixel AUROC / pixel AP)
2. Image-level anomaly detection (影像級判斷，評估 image AUROC / image AP)

本研究重點為跨資料集泛化，例如訓練在 ViSA dataset 但測試在 Mvtec dataset，其挑戰在於許多方法在提升 image AUROC 時，常會透過 image loss 的梯度回傳去改變 backbone/patch 表徵，導致 pixel map 被「影響」而下降。反之，若過度強化 pixel supervision，image score 可能不夠判別、對背景與多姿態變動敏感。

B. Overall Framework

我們以 AA-CLIP 的 two-stage zero-shot anomaly detection 框架為基底，保留其「異常語義 (anomaly-aware semantics)」的核心思想，並在 Stage 2 系統性引入 Pixel-preserving image supervision 與 frequency-aware adapter + learnable fusion，形成改良模型 Falcon-CLIP。

相較於原始 AA-CLIP，本模型在不破壞語義錨點 (semantic anchor) 的前提下，顯著提升 image-level anomaly detection 的穩定性，同時維持 pixel-level anomaly localization 的品質，特別適用於 zero-shot 跨資料集設定 (train on ViSA, test on MvTec)。

整體架構包含：

- **Frozen CLIP Image Encoder** (如 ViT-L-14-336)
- **Frozen CLIP Text Encoder** (Stage-1 learned anomaly-aware prompts)
- **Feature Adapters (ours)** : frequency-aware high-pass residual + learnable gating
- **Multi-scale Segmentation Branch** : 多層 patch tokens 與 text embeddings 計算 similarity maps
- **Image Scoring Branch (ours)** : seg-derived pooling 或 gradient-decoupled head

記號定義 (Notation Alignment)

給定輸入影像 x ，經 CLIP vision encoder 取得多層 patch tokens：

$$\{Z^{(l)}\}_{l=1}^L, Z^{(l)} \in \mathbb{R}^{B \times N \times C},$$

其中 B 為 batch size, N 為 patch 數, C 為特徵維度。文本端 (normal / abnormal prompts) 對應嵌入為：

$$t_n, t_a \in \mathbb{R}^C,$$

第 l 層的 patch-to-text similarity map 定義為：

$$S^{(l)} = Z^{(l)} t^\top \in \mathbb{R}^{B \times N}.$$

Stage 1 : Text Encoder Learning

(Anomaly-aware Semantic Space Construction)

Stage 1 的目標並非影像-文本對齊，而是先在文本嵌入空間中建立一個 **穩定且可泛化的異常語義空間**，作為後續影像對齊與異常判斷的語義錨點。

我們透過大量 normal / abnormal textual prompts 微調 Text Encoder，並引入 **Disentangle / Orthogonal Loss**：

$$\mathcal{L}_{\text{orth}} = (\mathbb{E}[t_n \cdot t_a])^2,$$

鼓勵正常與異常語義方向在嵌入空間中趨於正交。此設計使 Stage 1 的輸出成為一組 **class-agnostic、dataset-agnostic 的 Anchor Text Embeddings**，為 zero-shot anomaly detection 奠定語義基礎。

完成 Stage 1 後，Text Encoder 在 Stage 2 完全凍結，以確保異常語義空間的穩定性，避免後續 image supervision 反向扭曲語義結構。

Stage 2 : Image-Text Alignment

(Semantic Alignment and Stabilization)

在 AA-CLIP 及多數 VLM-based ZSAD 方法中，image-level anomaly score 通常直接由 global token (如 det_token) 估計，其 image-level loss 的梯度會回傳至 patch tokens，容易破壞已對齊的 pixel-level similarity 結構，導致 **pixel drop**，在跨資料集 zero-shot 設定下尤為明顯。為避免此問題，Falcon-CLIP 在 Stage 2 採取以下核心原則：

在固定 anomaly-aware text space 的前提下，僅更新 Image Encoder 中的 Adapter 與 Projector，使影像局部 patch 表徵對齊語義錨點，而不重新塑造語義本身。

基於此原則，Stage 2 被明確定義為 **影像-文本語義對齊與穩定化 (alignment and stabilization)** 的階段，而非單純追求 image-level 分數提升的分類訓練。

透過 **frequency-aware adapters、learnable fusion、以及 pixel-preserving image supervision**，模型能在提升 image AUROC 的同時，維持 pixel-level anomaly localization 的可靠性，實現穩定且可控的 zero-shot anomaly detection。

C. Model Optimization Strategy

本研究在模型結構上實施了以下三項關鍵改進，以提升對細微瑕疵的感知力：

1. Adapter: Frequency-aware High-pass Adapter (高頻感知殘差設計)

在原始 AA-CLIP 中，Image Encoder 內的 Adapter 僅透過線性投影或輕量化 MLP 對特徵進行轉換，其主要功能在於提供有限的參數適配能力。然而，此類設計 **傾向於保留低頻與整體語義資訊**，對於工業影像中常見的高頻紋理變化與細微缺陷 (subtle defects) 則較為不敏感，進而限制了 pixel-level anomaly localization 的表現，特別是在 zero-shot 跨資料集情境下。

為彌補此不足，本研究提出一種 **Frequency-Aware Adapter (頻率感知 Adapter)**，其核心理念是：在保持原有語義表徵穩定的前提下，**顯式強化高頻殘差訊號**，提升模型對細微紋理異常的感知能力。

設計動機與直觀解釋：在工業異常檢測中，許多關鍵異常 (如刮痕、裂縫、污染或局部材質變化) 主要體現在 **高頻紋理差異**，而非全域結構變化。若 Adapter 僅進行平滑的線性轉換，這類高頻訊號往往會被稀釋或忽略。

因此，我們借鑒生物視覺中「**獵鷹視覺 (falcon vision) 對細微紋理高度敏感**」的概念，將 Adapter 設計為能夠顯式提取並放大高頻殘差的結構，使模型在不破壞原有語義對齊的情況下，仍能有效捕捉局部異常訊號。

Frequency-Aware Adapter 設計 (數學形式)

給定 Adapter 的中間輸出特徵 y ，我們首先計算其期望值 (或 batch-wise mean) 以估計低頻成分，並提取高頻殘差：

$$y_{hp} = \alpha \cdot (y - \mathbb{E}[y])$$

其中：

- y_{hp} 為高頻殘差特徵 (high-pass residual)
- α 為 **可學習的純量參數 (learnable scalar)**，用以自動調節高頻增強強度 (實作中即為 log 中所觀察到的 hp_alpha)


接著，最終 Adapter 輸出透過殘差方式進行融合：

$$Z' = Z + \Delta(Z) + y_{hp}$$

其中：

- Z 為原始輸入特徵
- $\Delta(Z)$ 表示原始 Adapter 的線性或 MLP 投影分支
- y_{hp} 顯式補充高頻紋理資訊

此設計可視為在標準 Adapter 結構上，引入一條 **High-Pass Branch**，專門負責提取並強化高頻特徵，而不干擾原有的語義對齊路徑。



▲ Fig.7 Frequency-Aware High-Pass Adapter

2. Feature Integration: Learnable Gating (可學習融合閘門)

設計動機 (Motivation)：在 zero-shot anomaly detection 的跨資料集設定 (例如 **train on VisA, test on MVTec**) 中，不同資料集與不同 Transformer 層 (early vs. late layers) 對異常模式 (anomaly patterns) 的依賴程度並不相同。然而，在原始 AA-CLIP 中，Adapter 輸出與原始特徵之融合方式採用固定權重的殘差加總，即直接將 Adapter 輸出加回原始 token 表徵。此種固定融合策略隱含假設：

所有層級、所有資料集皆應以相同比例依賴 Adapter 所引入的新特徵。

在實務上，此假設往往不成立，並可能導致：

- 部分層級的 Adapter 過度主導特徵表徵
- 原始、具泛化性的 CLIP 特徵被過度覆蓋
- 跨資料集 zero-shot 泛化能力下降

為此，我們引入 **Learnable Gating Mechanism**，使模型能根據不同層級與資料特性，動態平衡原始特徵與 Adapter 特徵的貢獻比例。

記號定義 (Notation Alignment)

依照前述記號定義，第 l 層之輸入 patch tokens 表徵為：

$$Z^{(l)} \in \mathbb{R}^{B \times N \times C}$$

經過 Adapter (包含線性/MLP 分支與高頻殘差分支) 後，得到 Adapter-enhanced 特徵：

$$\tilde{Z}^{(l)} = Z^{(l)} + \Delta(Z^{(l)}) + y_{hp}^{(l)}$$

其中 $\Delta(\cdot)$ 與 $y_{hp}^{(l)}$ 的定義已於前節 Frequency-Aware Adapter 中說明。

Learnable Gating 設計 (Mathematical Formulation)

為動態控制原始特徵與 Adapter-enhanced 特徵之融合比例，我們引入一個可學習的門控函數 (gating function)。對於第 l 層，每一層皆學習一個 gating 值 $g^{(l)} \in [0, 1]$ ，其定義為：

$$g^{(l)} = \sigma(\omega^{(l)} \cdot \phi(Z^{(l)}) + b^{(l)})$$

其中：

- $\sigma(\cdot)$ 為 Sigmoid 函數

- $\phi(\cdot)$ 表示對 token 特徵進行簡單聚合 (例如 mean pooling)，以產生 gating 的輸入表示
- $\omega^{(l)}, b^{(l)}$ 為可學習參數


最終，第 l 層的輸出特徵定義為：

$$Z_{out}^{(l)} = g^{(l)} \cdot \tilde{Z}^{(l)} + (1 - g^{(l)}) \cdot Z^{(l)}$$

直觀解釋 (Intuition)：此 gating 機制允許模型在不同層級中，自動學習以下行為：

- 當 Adapter 提供有助於異常判別的補充資訊時 (例如高頻紋理異常)：→ $g^{(l)}$ 趨近 1，增加 Adapter-enhanced 特徵的影響力
- 當原始 CLIP 特徵更具泛化性時 (例如跨資料集測試)：→ $g^{(l)}$ 趨近 0，保留原始語義穩定的特徵表示

因此，該機制可視為一種 **layer-wise, data-adaptive feature balancing strategy**，而非單純的特徵加總。



▲ Fig.8 Feature Integration Strategy Comparison

3. Four patches: Learnable Multi-scale Fusion (多尺度可學習融合)

設計動機 (Motivation)：在 zero-shot anomaly detection 的跨資料集設定 (例如 **train on VisA, test on MVTec**) 中，不同資料集對異常線索的依賴層級並不相同。具體而言：

- **早期層 (early layers)** 通常對局部紋理與邊緣變化較為敏感
- **後期層 (late layers)** 則更偏向全域語義與結構資訊

然而，在原始 AA-CLIP 中，多層 Transformer tokens 或 feature maps 通常透過固定方式進行融合 (如直接 sum 或 mean)，其隱含假設為：

所有層級對 anomaly detection 的貢獻程度相同，且在不同資料集間具有一致性。

在實務上，此假設在跨資料集 zero-shot 設定下往往不成立，並可能導致以下問題：

- 對某些資料集關鍵的層級特徵被平均稀釋
- 模型無法根據 domain shift 自動調整層級偏好

- 整體 anomaly score 對資料集變化敏感，泛化能力受限

為解決上述問題，本研究引入 **Learnable Multi-scale Fusion** 機制，使模型能夠自動學習不同層級特徵在 anomaly detection 中的相對重要性。

• 記號定義 (Notation Alignment)

依照前述記號定義，經 Image Encoder 與 Adapter 處理後，我們可取得來自不同 Transformer 層的 patch token 表徵：

$$\{Z^{(l)}\}_{l=1}^L, Z^{(l)} \in \mathbb{R}^{B \times N \times C}$$

其中：

- l 表示第 l 個 Transformer 層
- B 為 batch size
- N 為 patch token 數
- C 為特徵維度

這些多層特徵共同構成 multi-scale 表徵集合，後續將用於 anomaly scoring。

• Learnable Multi-scale Fusion 設計 (Mathematical Formulation)

為避免固定融合策略的限制，我們為每一層引入一個可學習的層級權重參數 w_l 。首先，透過 softmax 正規化，使所有層級權重形成一個可比較、可解釋的分佈：

$$\alpha_l = \frac{\exp(w_l)}{\sum_{k=1}^L \exp(w_k)}$$

其中 α_l 表示第 l 層在多尺度融合中的相對貢獻比例。

最終，多尺度融合後的特徵表示定義為：

$$V = \sum_{l=1}^L \alpha_l \cdot Z^{(l)}$$


此設計使模型能在訓練過程中，自動調整不同層級特徵的權重分配，而非依賴人工設定或固定規則。

直觀解釋 (Intuition)

Learnable Multi-scale Fusion 允許模型根據資料分佈與異常型態，自主學習以下行為：

- 當異常主要表現在細微紋理或局部缺陷時：
→ 權重自然偏向 early layers，以強化高解析度局部訊號
- 當異常涉及結構性或語義層級差異時：
→ 權重自動偏向 late layers，以利用更抽象的語義資訊

因此，該機制可視為一種 **layer-adaptive representation aggregation strategy**，能有效因應跨資料集 (domain shift) 所帶來的特徵重要性變化 (如 Fig. 9 所示)。



▲Fig.9 Fusion Strategy Comparison

4. Anomaly High-Freq Augmentation (異常高頻增強)

設計動機 (Motivation)：在工業異常檢測中，許多關鍵缺陷 (如細微刮痕、裂縫、污染或材質異變) 主要體現在**高頻紋理變化**，而非整體結構差異。然而，在標準訓練流程中，模型往往更容易依賴低頻或全域語義線索，導致對細微異常的敏感度不足，特別是在 zero-shot 跨資料集設定下。為進一步強化模型對高頻異常線索的感知能力，本研究在 **Stage 2 的訓練階段**，提出一種 **Anomaly-aware High-Frequency Augmentation** 策略，透過受控方式引導模型專注於異常區域中的高頻變異。

方法概述 (Method Overview)

具體而言，我們利用訓練資料中可取得的 **Ground Truth Anomaly Mask**，僅在標註為異常的區域 (anomaly regions) 中注入高頻噪聲紋理 (high-frequency noise texture)，而保持正常區域 (normal regions) 不變，如 Fig. 10 所示。

此策略具有以下兩個關鍵特性：

1. **區域選擇性 (Region-selective)：**
高頻擾動僅作用於異常區域，避免破壞正常區域的語義與統計分佈。
2. **頻率導向 (Frequency-oriented)：**
所注入的噪聲以高頻成分為主，模擬實際工業缺陷中常見的細微紋理變化。

設計理由 (Design Rationale)

與對整張影像進行隨機噪聲或紋理擾動不同，本研究的設計遵循以下原則：

避免破壞 zero-shot 假設：若對整張影像或正常區域進行高頻擾動，可能導致模型學習到非語義相關的噪聲模式，進而削弱跨資料集泛化能力。

- **強化 anomaly-specific cues：**僅在異常區域注入高頻變異，可迫使模型在訓練過程中學會「哪些高頻訊號是真正與異常相關的」，而非將高頻紋理視為背景雜訊。
- **與 Frequency-Aware Adapter 形成互補：**此資料增強策略與前述 Frequency-Aware High-Pass Adapter 在設計上相互呼應：

- Adapter 負責在特徵層級強化高頻殘差
- Augmentation 則在資料層級增加高頻異常樣本的多樣性

兩者共同提升模型對細微缺陷的感知能力。

訓練效果與直觀解釋 (Effect and Intuition)

透過 Anomaly High-Frequency Augmentation，模型在 Stage 2 訓練時被引導：

- 將注意力集中於異常區域中的高頻紋理變化
- 避免過度依賴低頻或全域語義線索
- 提升對 subtle defects 的穩定辨識能力

在 zero-shot 跨資料集測試中，此策略有助於縮小不同資料集間的紋理分佈落差，進一步提升 image-level anomaly detection 的穩定性，同時不犧牲 pixel-level localization 表現。

原始 AA-CLIP 並未在訓練階段引入針對異常區域的頻率導向資料增強策略，其模型主要依賴特徵層級的適配學習。相較之下，本研究：

- 在 **資料層級 (data-level)** 顯式強化高頻異常訊號
- 並與 **特徵層級 (feature-level)** 的 Frequency-Aware Adapter 形成協同設計

此雙層次的高頻建模策略，特別有利於提升對工業場景中細微異常的檢測能力。




Fig.10 Anomaly High-Freq Augmentation

5. Training Strategy : Pixel-preserving Image Supervision

在 Stage 2，我們以維持 pixel-level anomaly localization 穩定性為核心訓練原則，目標是在提升 image-level anomaly detection 能力的同時，避免 image supervision 的梯度回傳干擾已對齊的 patch-level 表徵，造成 pixel performance 下降 (pixel drop)，此問題在 zero-shot 跨資料集設定中特別顯著。

為此，我們提出 Seg-derived Image Score：image anomaly score 不再直接由 global token (如 `det_token`) 估計，而是由 multi-scale patch-to-text similarity maps 反推而得。對每一層計算 abnormal similarity map，並透過 `max / top-k`, `k` pooling 聚合為 image score；關鍵在於，此過程以 `no_grad / detach` 切斷梯度，使 image loss 僅作為評分依據，而不影響 pixel 分支。

此外，為進一步降低風險，我們亦提供 gradient decoupling (image loss 僅更新 head / adapter) 以及 progressive image supervision schedule (先 seg-only，後期再逐步引入 image loss)，實驗顯示在 40 epochs 內即可達到穩定收斂，且不犧牲 zero-shot 泛化能力。

6. Loss Functions

整體訓練目標函數定義為多項 loss 的加權組合：

$$\mathcal{L} = \lambda_{\text{seg}} \mathcal{L}_{\text{seg}} + \lambda_{\text{pixmap}} \mathcal{L}_{\text{pixmap}} + \lambda_{\text{ms}} \mathcal{L}_{\text{ms}} + \lambda_{\text{img}} \mathcal{L}_{\text{img}},$$

其中權重依訓練排程動態調整。

- $\mathcal{L}_{\text{seg}}$ 為 pixel segmentation loss，利用 normal / abnormal text anchors 生成 anomaly map 並進行 weak supervision；
- $\mathcal{L}_{\text{pixmap}}$ 強化 pixel-image consistency，使 image-level score 與 pooled pixel evidence 保持一致，避免背景語義偏移；
- $\mathcal{L}_{\text{ms}}$ 為 multi-scale consistency loss，用以抑制單層噪聲並提升跨尺度穩定性；
- $\mathcal{L}_{\text{img}}$ 則進行 image-level anomaly classification，其梯度是否回傳至 backbone 則依 Training Strategy 中的 decoupling 設計決定。此設計確保 image supervision 始終建立在 pixel evidence 之上，而非主導其表徵學習。

7. Inference Strategy (Zero-shot Setting)

在推論階段，我們對每一層計算 normal 與 abnormal similarity maps，並透過 learnable 或固定權重進行 multi-scale 融合，生成最終 pixel-level anomaly map。image-level anomaly score 則優先採用 **seg-derived pooling**，與訓練策略保持一致，對背景與 domain shift 更具魯棒性；`det_token` 僅作為 ablation 或 fallback。此外，相較原始 AA-CLIP，我們進一步引入三項推論優化：(1) 以 `Normalize + einsum` 取代直接 `matmul`，加速相似度計算並提升數值穩定性；(2) 簡化 anomaly score 為 $A - N$ (abnormal minus normal similarity)；(3) 採用 **Top-k pooling** 聚焦最顯著的異常 patch，有效抑制背景噪聲。整體推論流程在不增加額外訓練成本的前提下，同步提升 image AUROC 與 zero-shot 穩定性。

V. EXPERIMENTAL RESULTS

A. Dataset and Experimental Setup

為驗證 Falcon-CLIP 的效能與泛化能力，本研究採用了跨領域的數據集配置：

1. 訓練集：模型主要在 MVTEC-AD (工業異常) 與 VISA (視覺異常) 兩個標準數據集上進行訓練。
2. 測試集：為了測試模型的零樣本遷移能力，我們在 7 個不同的數據集上進行了評估，涵蓋兩大領域：
 - 工業領域：MVTEC-AD、VISA、MPDD (Painted Defects)、BTAD (Tech Anomaly)。
 - 醫療領域：Brain MRI、Liver、Retina、Colonoscopy (包含 clinicDB, colonDB, Kvasir, CVC-300 四個子集)。
3. 評估指標：遵循 AA-CLIP 的標準，採用 Pixel-AUROC 與 Image-AUROC 作為主要評估指標。

B. Quantitative Analysis

實驗結果顯示，Falcon-CLIP 在多數數據集上均超越了基線模型 AA-CLIP。詳細數據比較如 TABLE I 所示。

TABLE I. EXPERIMENTAL RESULT

Source DS	Target DS	Ours Pixel AUROC	Ours Image AUROC	Paper Pixel AUROC	Paper Image AUROC
VISA	MVTec	92.25	91.79	91.9	90.5
VISA	MPDD	97.05	88.71	96.1	75.1
VISA	BTAD	96.48	91.59	97	94.8
VISA	Brain	96.65	78.75	95.5	80.2
VISA	Liver	96.67	59.86	97.8	69.7
VISA	Retina	97.05	88.71	95.5	82.7
VISA	Colon_clinicDB	89.93	NA	89.9	NA
VISA	Colon_colonDB	83.41	NA	84	NA
VISA	Colon_Kvasir	87.1	NA	87.2	NA
VISA	Colon_cvc300	95.47	NA	96.4	NA
MVTec	VISA	95.53	82.1	95.5	84.6
	Average	93.41727273	83.07285714	93.34545455	82.51428571

分析重點：

1. 工業場景的顯著突破：在 MPDD (Painted Defects) 數據集中，Falcon-CLIP 的 Image AUROC 達到 97.05%，相較於 Baseline 的 75.1% 取得了巨大的提升。這歸功於我們的高通適配器 (High-Pass Adapter) 與高頻噪聲增強策略，使其能精確捕捉金屬表面噴漆這類高頻紋理異常。
2. 穩定的泛化能力：在未經專門訓練的醫療影像（如 Brain MRI, Retina）中，模型依然保持領先，證明了其從工業視覺遷移至醫療診斷的穩定性。

C. Qualitative Analysis and Case Studies

為了深入理解 Falcon-CLIP 的行為模式，我們除了量化指標外，亦針對熱力圖進行了詳細的視覺化分析。雖然模型在 MPDD 等工業數據集上表現卓越，但透過分析失敗案例，我們發現模型在特定類型的異常感知上仍存在瓶頸。

1. Success cases

在 MVTEC 與 VISA 的多數類別中，Falcon-CLIP 能精準定位異常。特別是在具備高頻紋理特徵的瑕疵（如刮痕、異物附著）上，得益於我們引入的高通適配器 (High-Pass Adapter)，模型能有效抑制背景雜訊並鎖定目標（如 Fig. 11,12,13,14 所示）。

MVTEC: Success case




Fig.11 Success case on MVTEC

ViSA : Success case




Fig.12 Success case on ViSA

Medical : Success case




Fig.13 Success case on Medical

MPDD : Success case




Fig.14 Success case on MPDD

2. Failure cases and limitation discussion

儘管整體效能優異，從錯誤樣本中我們歸納出模型在以下三個面向面臨顯著挑戰：

1.1 細微異常的定位不穩

在 PCB 類別中，模型對於極細微的物理缺陷表現有限。例如接腳的輕微歪斜、焊點不規則，或是材料表面的極細微裂縫。由於這些異常僅佔據極少的像素且特徵不明顯，模型往往無法穩定地聚焦於真正的異常位置。這導致生成的熱力圖分佈較為發散，異常區域不夠集中，進而拉低了像素級定位準確度（如 Fig. 15 所示）。

1.2 大範圍語意型結構異常的缺失

模型在處理「整體語意結構被破壞」的異常時同樣面臨挑戰。以 MVTEc 中的 Transistor Missing 為例，這類異常雖然在視覺範圍上相當明顯，但其本質屬於「結構缺失」而非局部的紋理變化（如 Fig. 16 所示）。由於 Falcon-CLIP 的設計主要強化了對局部紋理與高頻細節的捕捉，對於需要全域理解的結構性異常仍缺乏足夠的感知力，導致無法有效辨識「元件整體不存在」這類邏輯性瑕疵。

ViSA : Failure case




Fig.15 Failure Case on ViSA: pcb

MVTEC: Failure case




Fig.16 Failure Case on MVTEC: Transistor

1.3 醫療影像中的結構變異干擾

當模型延伸至醫療影像場景時，上述問題被進一步放大。醫療影像（如腫瘤偵測）具有個體間結構差異極大、正常與異常界線模糊的特性。我們觀察到，在面對體積小、對比度低的腫瘤或病灶時，模型容易受到複雜背景結構的干擾，無法將注意力準確集中在真正的病變區域（如 Fig. 17 所示）。這與工業影像中的細微瑕疵問題高度相似，但在醫療場景下，由於缺乏標準的「正常模板」，其判斷難度更高。

Medical : Failure case




Fig.17 Failure Case on Medical

本研究針對現有視覺語言模型於異常檢測任務中普遍存在的異常感知缺失（Anomaly-Unawareness）問題，提出了一套受獵鷹視覺機制啟發的 Falcon-CLIP 架構。我們將傳統 CLIP 以靜態特徵對齊為主的設計，延伸為具備動態紋理感知能力的異常導向系統，透過引入 Frequency-Aware High-Pass Adapter 與 Layer-wise Learnable Gating，並結合針對異常區域的高頻噪聲注入訓練策略與 Top-k Pooling 影像層級推論機制，顯著強化模型對高頻紋理瑕疵與局部異常訊號的辨識能力。實驗結果顯示，Falcon-CLIP 在多個工業異常檢測資料集上均展現穩定且顯著的效能提升，尤其在 MPDD 資料集上，Image-AUROC 提升至 97.05%，有效驗證了所提出設計在零樣本（zero-shot）設定下的實用性與穩定性。此外，模型亦成功展現由工業視覺場景遷移至醫療影像領域（如 MRI 與大腸鏡影像）的潛力，顯示其在跨領域異常檢測任務中的良好泛化能力。然而，透過失敗案例分析，我們亦觀察到 Falcon-CLIP 在若干情境下仍存在感知瓶頸，包括：極細微且低對比的瑕疵（如微小裂縫）、缺乏明顯紋理線索的全域語意異常（如元件缺失），以及高結構變異與複雜背景的醫療影像場景。這些限制顯示，僅依賴局部高頻紋理線索仍不足以全面涵蓋所有異常型態。基於上述觀察，未來研究將聚焦於引入全域結構先驗與跨模態輔助訊息，並進一步強化多尺度訊號的層級建模能力，以期構建一套同時兼具細節感知與全域結構理解的通用異常檢測框架。

TEAM CONTRIBUTION

組員	主要貢獻
109003814 林士智	算法設計、程式實作、實驗驗證
114064545 謝尚哲	簡報統整、影片錄製與報告、圖表整理
113034506 李家欣	書面報告統整、圖表整理
112064520 陳若瑛	圖表整理、實驗驗證
114033636 蔡旻諾	簡報統整

REFERENCES

- [1] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, et al. 2021. Learning transferable visual models from natural language supervision. In International conference on machine learning. PMLR, 8748–8763.
- [2] Wenxin Ma, Xu Zhang, Qingsong Yao, Fenghe Tang, Chenxu Wu, Yingtai Li, Rui Yan, Zihang Jiang, and S. Kevin Zhou. 2025. AA-CLIP: Enhancing Zero-shot Anomaly Detection via Anomaly-Aware CLIP. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition.
- [3] Jongheon Jeong, Yang Zou, Taewan Kim, Dongqing Zhang, Avinash Ravichandran, and Onkar Dabeer. 2023. Winclip: Zero-/few-shot anomaly classification and segmentation. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 19606–19616.
- [4] Qihang Zhou, Guansong Pang, Yu Tian, Shibo He, and Jiming Chen. 2024. AnomalyCLIP: Object-agnostic Prompt Learning for Zero-shot Anomaly Detection. In The Twelfth International Conference on Learning Representations.
- [5] Yunkang Cao, Jiangning Zhang, Luca Frittoli, Yuqi Cheng, Weiming Shen, and Giacomo Boracchi. 2024. Adapclip: Adapting clip with hybrid learnable prompts for zero-shot anomaly detection. In European Conference on Computer Vision. Springer, 55–72.